

Praktikum 11 – Machine Learning K-Means Clustering

Prepared By:

Dr. Sirojul Munir S.Si,M.Kom

Diah Ayu Puspasari

Elyas Randi Renaldi

Tujuan :

1. Menjelaskan konsep dasar algoritma **K-Means Clustering** dan mengimplementasikannya untuk kasus *unsupervised learning* pada data bunga **Iris**, mulai dari tahap *preprocessing* hingga evaluasi *clustering* menggunakan *Elbow Method* dan *Silhouette Score*.

Dateline : 1 Pekan

Gitlab/Github :

Branch Repository : [PRODI ROMBEL]_[NAMASINGKAT]_[NIM] (contoh: ti01_budi_0110112001)

Aturan Pengerjaan:

1. Gunakan text editor yang nyaman bagi anda
2. Diperkenankan mengerjakan langsung bagi yang sudah memahami dan menguasai materi
3. Dilarang melakukan tindakan plagiarisme (asisten lab akan mengecek hasil pekerjaan)
 - a. 1x nilai praktikum terkait bernilai 0
 - b. 2x nilai matakuliah pemrograman web E
 - c. 3x mahasiswa akan di sidang komite etik kampus

Pendahuluan

K-Means Clustering adalah salah satu algoritma unsupervised machine learning yang paling populer. Tujuannya adalah membagi sekumpulan data menjadi K kelompok (cluster), di mana setiap titik data termasuk ke cluster yang memiliki titik pusat (centroid) terdekat.

- Prinsip Kerja: Algoritma ini secara iteratif menghitung jarak setiap titik data ke semua centroid dan menetapkan titik data ke cluster terdekat. Setelah semua data terdistribusi, centroid baru dihitung sebagai rata-rata dari semua titik data dalam cluster tersebut, dan proses diulang hingga centroid tidak lagi bergerak signifikan.
- Perbedaan dengan SVM: Berbeda dengan SVM yang merupakan Supervised Learning (membutuhkan label atau kolom Species untuk melatih model klasifikasi), K-Means adalah Unsupervised Learning. Ini berarti K-Means mencoba menemukan struktur dan pola tersembunyi (cluster) dalam data tanpa menggunakan label yang sudah ada, melainkan hanya dari fitur-fitur data.

Langkah Awal:

Sebelum memulai praktikum ini, pastikan Anda telah menyiapkan struktur folder di Google Drive / Jupyter seperti pada praktikum sebelumnya. Untuk praktikum ke-11, buat sub-folder baru dengan nama praktikum011/ di dalam direktori utama praktikum_ml/.

Struktur folder yang digunakan adalah sebagai berikut:

```
praktikum_ml/
├─ praktikum01/
├─ praktikum02/
├─ praktikum03/
│   └─ data/
│   └─ notebooks/
│   └─ model/
│   └─ reports/
```

Catatan:

1. Jika telah memiliki folder praktikum_ml, cukup tambahkan folder praktikum11.
2. Semua file notebook pada praktikum ini disimpan di dalam folder notebooks/ dengan nama praktikum11.ipynb.
3. Dataset ditempatkan di folder data/.
4. Model hasil training disimpan di folder model/ (format .pkl atau .joblib).
5. Visualisasi atau laporan hasil analisis disimpan di folder reports/. Jalankan file installer yang sudah diunduh.

Setelah itu, lakukan Langkah-langkah seperti biasa untuk Loading dataset. Mulai dari menghubungkannya dengan google drive sampai membaca dataset.

Praktikum K-Means Clusterig

1. Loading Dataset

Pada tahap ini dilakukan proses membaca dan menampilkan dataset yang akan digunakan untuk membangun model

```
import pandas as pd

# Read the CSV file with a comma delimiter
df = pd.read_csv('/content/Iris.csv')

# cetak header data (5 baris data) dari file
df.head()
```

...	Id	SepalLengthCm	SepalWidthCm	PetalLengthCm	PetalWidthCm	Species
0	1	5.1	3.5	1.4	0.2	Iris-setosa
1	2	4.9	3.0	1.4	0.2	Iris-setosa
2	3	4.7	3.2	1.3	0.2	Iris-setosa
3	4	4.6	3.1	1.5	0.2	Iris-setosa
4	5	5.0	3.6	1.4	0.2	Iris-setosa

Mengimpor library pandas, yaitu library Python yang digunakan untuk membaca, memproses, dan menganalisis data dalam bentuk tabel (DataFrame). Lalu, menampilkan 5 baris pertama dengan .head()

- Menampilkan informasi detail dengan df.info()

```
df.info()

*** <class 'pandas.core.frame.DataFrame'>
RangeIndex: 150 entries, 0 to 149
Data columns (total 6 columns):
#   Column                Non-Null Count  Dtype
---  ---
0   Id                    150 non-null   int64
1   SepalLengthCm         150 non-null   float64
2   SepalWidthCm          150 non-null   float64
3   PetalLengthCm         150 non-null   float64
4   PetalWidthCm          150 non-null   float64
5   Species               150 non-null   object
dtypes: float64(4), int64(1), object(1)
memory usage: 7.2+ KB
```

Perintah ini memberikan ringkasan lengkap dari dataset, seperti:

- Jumlah baris dan kolom
- Nama kolom beserta tipe datanya (object, int64, float64)
- Jumlah nilai yang tidak kosong (Non-Null Count)
- Total penggunaan memori dataset

- Cek Missing Value dan Data Duplikat

```
df.isnull().sum()

***      0
Id      0
SepalLengthCm  0
SepalWidthCm  0
PetalLengthCm  0
PetalWidthCm  0
Species      0

dtype: int64

df.duplicated().sum()

np.int64(0)
```

- Menampilkan statistika deskriptif dari dataset

```
df.describe()
```

	Id	SepalLengthCm	SepalWidthCm	PetalLengthCm	PetalWidthCm
count	150.000000	150.000000	150.000000	150.000000	150.000000
mean	75.500000	5.843333	3.054000	3.758667	1.198667
std	43.445368	0.828066	0.433594	1.764420	0.763161
min	1.000000	4.300000	2.000000	1.000000	0.100000
25%	38.250000	5.100000	2.800000	1.600000	0.300000
50%	75.500000	5.800000	3.000000	4.350000	1.300000
75%	112.750000	6.400000	3.300000	5.100000	1.800000
max	150.000000	7.900000	4.400000	6.900000	2.500000

- Cek nilai pada kolom Species
Perintah `df["Species"].unique()` digunakan untuk menampilkan daftar nilai unik pada kolom Species. Hasilnya menunjukkan bahwa dataset Iris memiliki tiga jenis bunga, yaitu Iris-setosa, Iris-versicolor, dan Iris-virginica.

```
df["Species"].unique()

array(['Iris-setosa', 'Iris-versicolor', 'Iris-virginica'], dtype=object)
```

- Menghitung jumlah pada kolom Species
Selanjutnya, perintah `df["Species"].value_counts()` digunakan untuk menghitung jumlah data pada setiap kelas. Hasil yang ditampilkan menunjukkan bahwa masing-masing spesies memiliki 50 data, sehingga total keseluruhan adalah 150 data.

```
df["Species"].value_counts()

count
Species
Iris-setosa    50
Iris-versicolor 50
Iris-virginica 50
dtype: int64
```

Dari hasil ini dapat disimpulkan bahwa dataset Iris bersifat seimbang (balanced) karena setiap kelas memiliki jumlah data yang sama.

2. Pemilihan Fitur

Pada tahap ini dilakukan pemisahan antara fitur (X) dan label (y).

```
from sklearn.preprocessing import LabelEncoder
le = LabelEncoder()
df["SpeciesEncoded"] = le.fit_transform(df["Species"])

# Fitur untuk clustering
X = df.drop(["Species", "SpeciesEncoded"], axis=1)
```

- Pemilihan Fitur: Fitur (X) yang digunakan untuk clustering adalah kolom Id, SepalLengthCm, SepalWidthCm, PetalLengthCm, dan PetalWidthCm. Kolom Species dan SpeciesEncoded (yang merupakan hasil Label Encoding dari Species untuk keperluan perbandingan) dibuang dari data fitur yang digunakan untuk clustering.
- Label Encoding: Meskipun K-Means adalah unsupervised, kolom Species di-encode menjadi SpeciesEncoded (0, 1, 2) untuk tujuan evaluasi dan perbandingan hasil clustering dengan label asli di tahap akhir.

3. Menentukan Jumlah Cluster (K) dengan Elbow Method

Jumlah cluster optimal K ditentukan menggunakan Elbow Method, yang memplot nilai Inertia terhadap jumlah cluster.


```
from sklearn.cluster import KMeans
import matplotlib.pyplot as plt

inertia_list = []
K_range = range(1, 10)

for k in K_range:
    km = KMeans(n_clusters=k, random_state=42)
    km.fit(X)
    inertia_list.append(km.inertia_)

plt.figure(figsize=(7,5))
plt.plot(K_range, inertia_list, marker='o')
plt.title("Elbow Method untuk Menentukan Jumlah Cluster")
plt.xlabel("Jumlah Cluster (k)")
plt.ylabel("Inertia")
plt.grid(True)
plt.show()
```

Inertia merupakan ukuran seberapa baik data dikelompokkan, dihitung sebagai jumlah kuadrat jarak setiap titik data ke centroid cluster-nya. Nilai Inertia akan menurun seiring bertambahnya K. Sedangkan Elbow Point adalah titik pada grafik di mana penurunan Inertia mulai melambat secara signifikan, menyerupai siku. Titik ini menunjukkan jumlah cluster yang optimal.



Dari plot Elbow Method yang dihasilkan, terlihat jelas titik siku (elbow point) berada pada K= 3. Hal ini konsisten dengan jumlah spesies bunga Iris yang sebenarnya (3 spesies).

4. Membangun Model K-Means

```
from sklearn.cluster import KMeans
kmeans = KMeans(
    n_clusters=3,          # Karena dataset Iris ada 3 spesies
    init="k-means++",
    random_state=42
)
```

```
df["Cluster"] = kmeans.fit_predict(X)

print("Cluster ditemukan:", df["Cluster"].unique())

... Cluster ditemukan: [2 0 1]
```

- Inisialisasi Model: Model diinisialisasi dengan `n_clusters=3` (sesuai hasil Elbow Method) dan `init='k-means++'` (untuk pemilihan centroid awal yang lebih cerdas).
- Pelatihan dan Prediksi: Model dilatih menggunakan data fitur (X) dan hasil clustering (cluster prediksi) disimpan dalam kolom baru, `df["Cluster"]`.
- Hasil Cluster: Model berhasil menemukan 3 cluster (berlabel 0, 1, dan 2).

5. Evaluasi Kualitas Clustering

```
from sklearn.metrics import silhouette_score

sil_score = silhouette_score(X, df["Cluster"])
print("\n===== SILHOUETTE SCORE =====")
print("Silhouette Score:", sil_score)

===== SILHOUETTE SCORE =====
Silhouette Score: 0.5816702617893469
```

Kualitas hasil clustering diukur menggunakan Silhouette Score yang merupakan metrik untuk mengukur seberapa mirip suatu objek dengan cluster-nya sendiri (kohesi) dibandingkan dengan cluster lain (separasi).

- Nilai berkisar antara -1 sampai +1.
- Nilai mendekati +1 menunjukkan objek telah dikelompokkan dengan baik.
- Nilai mendekati 0 menunjukkan objek berada di antara dua cluster.
- Nilai mendekati -1 menunjukkan objek salah cluster.

Silhouette Score yang dihasilkan adalah 0.58167, menunjukkan bahwa cluster yang terbentuk memiliki separasi yang cukup baik.

6. Confusion Matrix (Perbandingan dengan Label Asli)


Meskipun K-Means tidak menggunakan label asli saat pelatihan, Confusion Matrix dapat digunakan untuk membandingkan hasil cluster (label prediksi) dengan label SpeciesEncoded (label asli/kebenaran).

```
from sklearn.metrics import confusion_matrix, classification_report
print("\n===== CONFUSION MATRIX =====")
cm = confusion_matrix(df["SpeciesEncoded"], df["Cluster"])
print(cm)

===== CONFUSION MATRIX =====
[[ 1  0 49]
 [49  1  0]
 [ 0 50  0]]
```

```
import matplotlib.pyplot as plt
import seaborn as sns


plt.figure(figsize=(6,5))
sns.heatmap(
    cm, annot=True, fmt='d', cmap='Blues',
    xticklabels=["Cluster 0", "Cluster 1", "Cluster 2"],
    yticklabels=le.classes_
)
plt.title("Confusion Matrix: K-Means vs Label Asli")
plt.xlabel("Cluster Prediksi")
plt.ylabel("Label Asli")
plt.show()
```



- Matriks ini menunjukkan bahwa clustering tidak secara langsung memetakan cluster (0, 1, 2) ke label asli (Iris-setosa, Iris-versicolor, Iris-virginica) dengan urutan yang sempurna.
- Misalnya, Iris-setosa (label asli 0) sebagian besar diprediksi sebagai Cluster 2 (49 data), bukan Cluster 0 (1 data).
- Ini adalah hal yang wajar dalam unsupervised learning karena K-Means hanya bertujuan mengelompokkan data berdasarkan kedekatan fitur, bukan mereplikasi label yang sudah ada.

7. 2D dan 3D Visualisasi Hasil Model K-Means

```
plt.figure(figsize=(7,5))
sns.scatterplot(
    x=df["SepalLengthCm"],
    y=df["SepalWidthCm"],
    hue=df["Cluster"],
    palette="deep"
)
plt.title("Visualisasi K-Means Clustering (2D)")
plt.xlabel("Sepal Length (cm)")
plt.ylabel("Sepal Width (cm)")
plt.show()
```



2D Plot (Sepal Length vs Sepal Width) ini menunjukkan bahwa cluster yang terbentuk cukup terpisah satu sama lain, terutama satu cluster yang jauh terpisah dari dua cluster lainnya. Hal ini mengindikasikan bahwa fitur kelopak bunga (Sepal) efektif memisahkan setidaknya satu jenis Iris.


```
fig = plt.figure(figsize=(10, 8))
ax = fig.add_subplot(111, projection='3d')

scatter = ax.scatter(
    df["SepalLengthCm"],
    df["PetalLengthCm"],
    df["PetalWidthCm"],
    c=df["Cluster"],
    s=60
)

ax.set_title("3D Plot K-Means Clustering pada Iris")
ax.set_xlabel("Sepal Length (cm)")
ax.set_ylabel("Petal Length (cm)")
ax.set_zlabel("Petal Width (cm)")

# Legend cluster
legend_labels = [f"Cluster {i}" for i in range(3)]
ax.legend(handles=scatter.legend_elements()[0], labels=legend_labels)

plt.show()
```



3D Plot (Sepal Length, Petal Length, Petal Width) merupakan plot tiga dimensi memberikan pandangan yang lebih komprehensif, menunjukkan bagaimana ketiga cluster (biru, hijau, merah) terpisah dengan baik dalam ruang 3D. Ini memvisualisasikan mengapa Silhouette Score bernilai cukup baik—data yang memiliki fitur serupa dikelompokkan bersama.

Tugas Praktikum Mandiri

- Explore Algoritma Clustering lain – DBSCAN
- Gunakan Koordinat GPS sebagai analisis Densitas dari Dataset